Pruebas/validaciones de calidad y guía para ejecutarlas

Con el objetivo de garantizar la calidad de los datos cargados en el esquema raw, se definieron y ejecutaron las siguientes validaciones:

1. Integridad

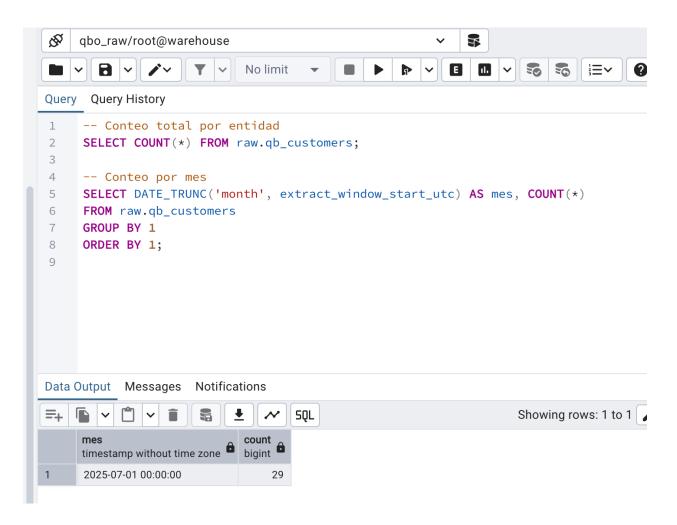
Se verificó que las claves primarias (id) no contengan valores nulos ni duplicados.

```
qbo_raw/root@warehouse
                              No limit
Query Query History
 1
      -- Verificar nulos
 2
      SELECT COUNT(*)
 3
      FROM raw.qb_customers
      WHERE id IS NULL;
      -- Verificar duplicados
      SELECT id, COUNT(*)
      FROM raw.qb_customers
 9
      GROUP BY id
10
      HAVING COUNT(\star) > 1;
11
Data Output Messages Notifications
                                     SQL
     [PK] text
               bigint 4
```

2. Volumetría

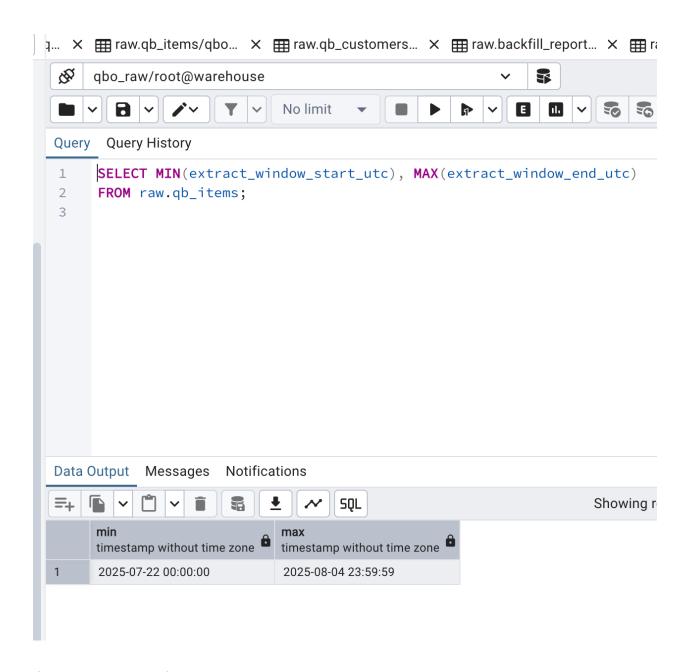
Se revisaron los conteos de registros por entidad y por tramo de fechas para confirmar que coincidan con los logs del data loader.

Como podemos observar, hay 29 filas únicas (las mismas que fueron cargadas desde la api)

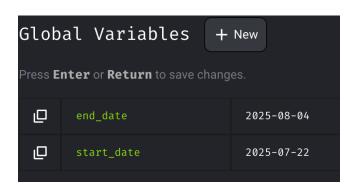


3. Coherencia temporal

Se validó que los timestamps de ingesta (ingested_at_utc) y las ventanas de extracción (extract_window_start_utc y extract_window_end_utc) sean consistentes con los filtros utilizados en el data loader.



Coinciden con los filtros determinados en el pipeline:



Reprocesos seguros (idempotencia)

Se volvió a ejecutar un mismo tramo de fechas y se verificó que el número de registros en la tabla raw no cambió, confirmando que la carga es idempotente. Además, en la tabla de reportes backfill_report aparecen múltiples ejecuciones del mismo rango con estado success.

Reporte de volumetría por tramo y evidencia de idempotencia

Al ejecutar el bloque **data loader**, es posible observar en los logs cómo avanza el proceso: la posición inicial, el número de intentos y la cantidad de *chunks* necesarios para procesar toda la información según el rango de fechas definido.

```
PY ■ DATA LOADER ► ingest qb customers ←X Edit parents
Nuevo access_token obtenido vía refresh_token
Chunk 1: 2025-07-01T00:00:00Z → 2025-07-07T23:59:59Z
Request API: 2025-07-01T00:00:00Z \rightarrow 2025-07-07T23:59:59Z, posición=1, intento 1
Posición 1 \rightarrow 0 customers
Chunk 1 devolvió 0 customers
Chunk 2: 2025-07-08T00:00:00Z → 2025-07-14T23:59:59Z
Request API: 2025-07-08T00:00:002 \rightarrow 2025-07-14T23:59:59Z, posición=1, intento 1
Posición 1 → 0 customers
Chunk 2 devolvió 0 customers
Chunk 3: 2025-07-15T00:00:00Z → 2025-07-21T23:59:59Z
Request API: 2025-07-15T00:00:00Z → 2025-07-21T23:59:59Z, posición=1, intento 1
Posición 1 \rightarrow 0 customers
Chunk 3 devolvió 0 customers
Chunk 4: 2025-07-22T00:00:00Z → 2025-07-28T23:59:59Z
Request API: 2025-07-22T00:00:00Z \rightarrow 2025-07-28T23:59:59Z, posición=1, intento 1
Posición 1 → 7 customers
Chunk 4 devolvió 7 customers
Chunk 5: 2025-07-29T00:00:00Z → 2025-08-04T23:59:59Z
Request API: 2025-07-29T00:00:00Z \rightarrow 2025-08-04T23:59:59Z, posición=1, intento 1
Posición 1 → 22 customers
Chunk 5 devolvió 22 customers
Chunk 6: 2025-08-05T00:00:00Z → 2025-08-11T23:59:59Z
Request API: 2025-08-05T00:00:00Z \rightarrow 2025-08-11T23:59:59Z, posición=1, intento 1
Posición 1 \rightarrow 0 customers
Chunk 6 devolvió 0 customers
Chunk 7: 2025-08-12T00:00:00Z → 2025-08-18T23:59:59Z
Request API: 2025-08-12T00:00:00Z \rightarrow 2025-08-18T23:59:59Z, posición=1, intento 1
Posición 1 \rightarrow 0 customers
Chunk 7 devolvió 0 customers
Chunk 8: 2025-08-19T00:00:00Z → 2025-08-25T23:59:59Z
Request API: 2025-08-19T00:00:00Z \rightarrow 2025-08-25T23:59:59Z, posición=1, intento 1
```

Cuando la ejecución finaliza, se imprime la cantidad total de registros procesados (ya sea *customers*, *invoices* o *items*).

```
Request API: 2025-08-12100:00:00Z → 2025-08-18T23:59:59Z, posición=1, intento 1
Posición 1 → 0 customers
Chunk 7 devolvió 0 customers
Chunk 8: 2025-08-19T00:00:00Z → 2025-08-25T23:59:59Z
Request API: 2025-08-19T00:00:00Z → 2025-08-25T23:59:59Z, posición=1, intento 1
Posición 1 → 0 customers
Chunk 8 devolvió 0 customers
Chunk 8 devolvió 0 customers
Chunk 9: 2025-08-26T00:00:00Z → 2025-08-31T23:59:59Z
Request API: 2025-08-26T00:00:00Z → 2025-08-31T23:59:59Z, posición=1, intento 1
Posición 1 → 0 customers
Chunk 9 devolvió 0 customers
Chunk 9 devolvió 0 customers
```

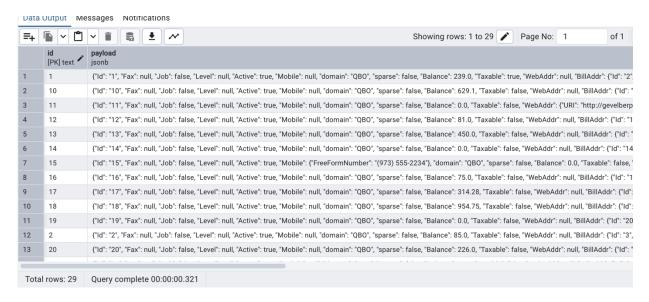
Posteriormente, en el bloque **transformer**, al convertir los datos en un DataFrame, en la esquina inferior izquierda de la tabla se puede confirmar el número total de filas, lo que permite validar la congruencia entre lo extraído y lo transformado.

PY	■ TRANSFORMER 🕒	transform_qb_custo	ners ←O 1 parent			•	▷ \$ ≅ ○ ^
			2025-09- 12T22:50:49.010141	2025-07-22T00:00:00Z	2025-07-28T23:59:59Z		{ "headers": {
			2025-09- 12T22:50:49.010141		2025-07-28T23:59:59Z		{ headers": {
			2025-09- 12T22:50:49.010141	2025-07-22T00:00:00Z	2025-07-28T23:59:59Z		{ "headers": {
			2025-09- 12T22:50:49.010141		2025-07-28T23:59:59Z		{ "headers": {
			2025-09- 12T22:50:49.010141	2025-07-22T00:00:00Z	2025-07-28T23:59:59Z		{ "headers": {
			2025-09- 12T22:50:49.010141	2025-07-22T00:00:00Z	2025-07-28T23:59:59Z		{ "headers": {
		{ "Active": true,	2025-09- 12T22:50:49.010141	2025-07-22T00:00:00Z	2025-07-28T23:59:59Z		{ "headers": {
		{ "Active": true,	2025-09- 12T22:50:49.010141	2025-07-29T00:00:00Z	2025-08-04T23:59:59Z		{ "headers": {
			2025-09-		2025-08-04T23:59:59Z		
							✓ C A

De igual manera, en el bloque **exporter**, se muestra cuántas filas fueron exportadas y a qué tabla específica en la base de datos se insertaron.

```
Exportando 29 customers a raw.qb_customers en warehouse:5432/qbo_raw Exportación completada: 29 customers procesados.
```

Finalmente, en **pgAdmin** se confirma que todas las filas fueron efectivamente exportadas.



Para verificar la **idempotencia**, se ejecuta nuevamente el pipeline para el mismo rango de fechas. En la tabla de reportes (backfill_report) se observa que existen dos ejecuciones con el mismo *window_start* y *window_end*, ambas exitosas. Al revisar nuevamente la tabla de la entidad en cuestión (por ejemplo, qb_customers), se confirma que el número total de filas se mantiene igual, lo que garantiza que no se generaron duplicados y que el proceso es efectivamente idempotente.

